

Projektdokumentation

Neuronale Nüsse

16.07.2026 – Aufbereitet – YemotaY

Inhalstangabe

0. Zielsetzung.....	2
1. Was ist ein KNN.....	2
2. Geschichte der KNN.....	3
3. Anforderungen an das Netzwerk.....	7
4. Datensätze.....	7
5. Architektur des Netzwerks.....	8
6. Modellentwicklung.....	8
7. Training des Modells.....	8
8. Ergebnisse/Fazit.....	9
9. Abkürzungen/Erklärungsverzeichnis.....	10
10. Bildquellenangaben.....	11

0. Zielsetzung


Das Ziel dieses Projekts ist es, ein Konvolutes neuronales Netzwerk¹ (KNN) von der Pike auf zu entwickeln, welches in der Lage ist, verschiedene Nussorten auf Bildern zu erkennen oder 3D Szenen. Das Netzwerk soll in der Lage sein neue Nussorten an zu lernen, danach die Nüsse automatisch zu erkennen und zu klassifizieren, indem es die Merkmale und Muster auf den Bildern analysiert. Das Netzwerk soll eine Genauigkeit von mindestens 90% bei der Erkennung der verschiedenen Nussorten aufweisen. Als verwendete Frameworks kommen Python/Tensorflow und Pytorch zum einsatz.

1. Was ist ein KNN


Ein KNN ist ein spezieller Typ künstlicher neuronaler Netze, der besonders gut Bilder und andere räumlich strukturierte Daten analysieren kann. Es erkennt automatisch Merkmale wie Kanten, Formen und Muster, indem es sogenannte Faltungs- (Konvolutions) Schichten verwendet. Dadurch wird es häufig für Aufgaben wie Bilderkennung, Objekterkennung und medizinische Bildanalyse eingesetzt. Außerdem erfreut es sich schon einer großen Bekanntheit.

Technischer gesagt, es sind Netze aus künstlichen Neuronen, deren Aufgabe es ist aufgaben selbständig Aufgaben zu lösen in dem Sie einen Input interpretiert und anhand von Erfahrungswerten, in Form von Gewichtungen, die best möglichste Antwort auf die Aufgabe, für die das KNN geschaffen wurde. Das Neuronen Modell lehnt sich stark an das Biologische Vorbild (Hirn) an. Wobei es sich mehr um eine Abstraktion der Informationsverarbeitung handelt ansonsten wäre es eher ein teil der Computergesteuerten Neurowissenschaften.

2. Geschichte der KNN



Die ersten die diese Begrifflichkeiten nutzen waren McCulloch und Pitts im Jahre 1943, die in dem Zusammenhang Arithmetische oder logische Funktion lösten. 4 Jahre später erkannten Sie dass damit auch Algorithmen zur Mustererkennung realisieren konnten.



1949 wird die Hebbsche Lernregel aufgestellt die in den meisten KNN's heute aufgegriffen wird. Nämlich die Dynamische Gewichts Anpassung und die daraus resultierende Dynamik und eigenständigkeit.


$$\Delta w_{i,j} = \eta \cdot o_i \cdot a_j$$

Gewichtsänderung von Neuron i nach j

Lernrate

Hebbsche Lernregel⁰⁰³

Im Jahr 1951 gelang Minsky dann mit seiner Doktorarbeit mithilfe selbstjustierender Neuronen am SNARC ein durchbruch jedoch war Rechenleistung noch zu teuer. 1957-1958 wurde der erste Algorithmus entwickelt von Wightmann und Rosenblatt, der Handgeschriebene Zahlen erkennen/lesen konnte. Mithilfe der Deltaregel. 1960 wurde dann das ADALINE (Adaptive Linear Neuron) Modell.




1969 wurde bewiesen, nach damaligem Stand, das Xor Problem nicht gelöst werden kann und auch andere Probleme in der Linearen Trennbarkeit auftreten können. Was die Forschungen in die Richtung erst mal Stoppte ([Hier extern dazu weiterlesen](#)).

Ab 1972 nimmt das ganze Thema langsam wieder Fahrt auf, dank Kohonen und seinem Modell des Assoziativspeichers:


Assoziativmatrix: Abfrageregeln

Frage-tupel 1: (0,0,1,1,0,0,0,1), Antwort-tupel 1: (1,0,1,0,1,1,0,0,0,1,0,0)




Assoziativmatrix⁰⁰⁵

1974 wird das Rückwärtspropagieren, das Fehlerrückführen, eingeführt was aber erst später seine Wichtigkeit erhalten sollte.




Rückwärtspropagation⁰⁰⁶

Ab 1976 entwickeln Grossberg und Carpenter die Adaptive Resonanztheorie, was das lernen von neuem ermöglichte ohne Gelerntes zu verwerfen.
 1982 Entwickelt John Hopfield die Hopfield netze.




Hopfield Netz⁰⁰⁷


1983, Kunihiko Fukushima, S. Miyake und T. Ito stellen das neuronale Modell Neocognitron vor.



1985 veröffentlicht Hopfield eine Lösung mithilfe eines seiner Netze, zum Botenproblem. Es wird ein Backpropagation of Error als Lernverfahren entwickelt und eine Verallgemeinerung der Delta-Regel. Somit werden nicht linear separierbare Probleme durch mehrschichtige Perceptrons.



Ab 2009 bekommen vor allem rekurrente, vorwärtsgerichtete Netze einen Aufwind. Gerade dank Jürgen Schmidhuber, der zusammen mit dem Schweizer KI Labor IDSIA eine Serie von 8 International renommierten Wettbewerben gewann, mithilfe des LTMS (long term-short memory) Schemas.



Ab 2016-2026 und mit annehmen und ankommen in der Breiten Masse von und bei ChatGPT, OPUS, Mythos und co wird immer Deutlicher wie wertvoll diese Technologie für die Menschheit ist und wir Sie nicht kaputt kommerzialisieren dürfen. Gerade im Bereich Medizin und Energie können wir mit Ihrer Hilfe noch Durchbrüche erzielen, welche dringend nötig würden. Sollten aber niemals die Kontrolle komplett abgeben.

3. Anforderungen an das Netzwerk

Das KNN muss folgende Anforderungen erfüllen und sollte hinterher der Lage sein:

- verschiedene Nusssorten auf Bildern zu erkennen und zu klassifizieren.
- eine Genauigkeit von mindestens 90% bei der Erkennung der verschiedenen Nusssorten zu erbringen.
- Nüsse unter verschiedenen Lichtbedingungen und Hintergründen zu erkennen.
- mehrere Nüsse auf einem Bild zu erkennen und zu klassifizieren.
- schnell und effizient zu Arbeiten außerdem in der Lage sein, große Mengen von Bildern zu verarbeiten.
- auf verschiedenen Geräten und Plattformen zu laufen, einschließlich mobiler Geräte (OPTIONAL).

4. Datensätze

Um das KNN zu trainieren, werden Bilder von verschiedenen Nusssorten benötigt. Ein geeigneter Datensatz sollte folgende Anforderungen erfüllen:

- ausreichend groß sein, um das Netzwerk zu trainieren.
- verschiedene Nusssorten enthalten, die in verschiedenen Winkeln und Positionen aufgenommen wurden.
- Nüsse unter verschiedenen Lichtbedingungen und Hintergründen enthalten.
- er sollte beschriftet sein, um das Netzwerk zu trainieren.

Des weiteren wurden eigens erstellte GLTF² Modelle aus Blender hinzugefügt, welche die Datenqualität um ein vielfaches zum Originalen Projektansatz gesteigert hat!

5. Architektur des Netzwerks

Das KNN sollte aus mehreren Schichten von „Convolutional Layers“³, „Pooling Layers“⁴ und „Fully Connected Layers“⁵ bestehen. Eine geeignete Architektur soll wie folgt aussehen:

- Eingangsschicht: Input Layer (mit der Größe der Bilder)
- Convolutional Layer: Extrahiert Merkmale aus den Bildern
- Pooling Layer: Reduziert die Größe der Feature-Maps
- Convolutional Layer: Extrahiert weitere Merkmale aus den Feature-Maps
- Pooling Layer: Reduziert die Größe der Feature-Maps
- Fully Connected Layer: Verarbeitet die extrahierten Merkmale und gibt eine Ausgabe zurück
- Ausgangsschicht: Output Layer (mit der Anzahl der Nussorten als Klassen)

6. Modellentwicklung

In der Modellentwicklungsphase wurde ein Grundmodell für das KNN erstellt und anhand von Testdaten validiert. Das Modell wurde anschließend optimiert und um eine Architektur für das finale Modell erweitert. Es wurden verschiedene Algorithmen und Hilfsscripte implementiert, um eine hohe Erkennungsgenauigkeit zu erreichen.

7. Training des Modells

In der Trainingsphase wurde das Modell mit einer großen Anzahl von Trainingsdaten trainiert und die Parameter wurden fein abgestimmt, um eine hohe Genauigkeit zu erreichen. Das Modell wurde anschließend anhand von Testdaten validiert und die Ergebnisse wurden optimiert.

8. Ergebnisse/Fazit

Das Anlernen und Speichern und Überwachen des Modells hat funktioniert. Leider konnte ich auch mit vielen guten Daten und einigem an Rechenleistung keine überzeugende Ergebnisse erzielen. Vielleicht bringen hier noch die 3D Modelle + Gerenderte Szenen einen Durchbruch.

Wodurch bei der Videoauswertung, ohne 3D Modelle trainiert, oft noch Müll raus kam.

Das Lernen und Erstellen eines eigenen neuronalen Netzes ist eine faszinierende und herausfordernde Aufgabe. Die Idee, ein System zu entwickeln, das in der Lage ist, komplexe Muster und Zusammenhänge zu erkennen und zu verarbeiten, ist faszinierend und hat unzählige Anwendungsbereiche in der Wissenschaft, Wirtschaft und Technologie. Es wird die Zukunft verändern und daher will ich diese Technik verstehen. Das tue ich nun nach dem Projekt.

Es erfordert ein tiefes Verständnis von Mathematik, Statistik und Informatik und das Lernen von verschiedenen Algorithmen + Technologien, um die Architektur des Netzes zu entwickeln und die optimale Struktur und Parameter des Netzes zu finden. Die Wahl der richtigen Datenquellen, die Vorverarbeitung und Analyse der Daten, sowie die Wahl der richtigen Fehlerfunktionen sind weitere Herausforderungen, die während des Entwicklungsprozesses zu berücksichtigen sind.

Das Training erfordert Geduld und Zeit, da es in der Regel viele Iterationen und Anpassungen erfordert, um die optimale Genauigkeit und Performance zu erreichen. Es ist eine ständige Auseinandersetzung mit den Daten, um sicherzustellen, dass das Modell kontinuierlich verbessert wird und in der Lage ist, Muster und Zusammenhänge in den Daten zu erkennen.

Es ist jedoch auch eine äußerst lohnende Erfahrung. Wenn das Modell erstellt ist und in der Lage ist, erfolgreich einfachste Probleme zu lösen, ist das Gefühl der Zufriedenheit und Erfüllung unbeschreiblich.

Sehr geholfen hat mir auf diesem Weg das Buch „Neuronale Netze mit Python“ vom Rheinwerk Verlag und unser gutes altes Wikipedia + meine Klassenkameraden aus der Ausbildung. Ein ganz Besonder Herzlicher Dank auch noch an Frau Brandner. Ohne einen von denen wäre ich so weit gekommen mit diesem Projekt <3

9. Abkürzungen/Erklärungsverzeichnis

1. Konvolutes neuronales Netzwerk – siehe Punkt 1
2. GLTF – Modernes Dateiformat für dreidimensionale Figuren + Textur.
3. Convolutional Layers / 4. Pooling Layers / 5. Fully Connected Layers → siehe Präsentation

10. Bildquellenangaben

- 001 - https://www.researchgate.net/figure/Timeline-of-deep-learning-adopted-from-20_fig1_344738477
- 002 - <https://de.wikipedia.org/wiki/McCulloch-Pitts-Zelle>
- 003 - <https://www.digisaurier.de/kleine-weltgeschichte-der-ki-1-vom-elektronenhirn-zu-neuronalen-netzen/hebb/>
- 004 - https://de.wikipedia.org/wiki/Datei:Adaline_modell-A-svg.svg
- 005 - <https://de.wikipedia.org/wiki/Assoziativmatrix>
- 006 - <https://methpsy.elearning.psych.tu-dresden.de/mediawiki/index.php/Backpropagation>
- 007 - <https://de.wikipedia.org/wiki/Hopfield-Netz>
- 008 - <https://gracewlindsay.com/2018/05/17/deep-convolutional-neural-networks-as-models-of-the-visual-system-qa/>
- 009 - https://www.researchgate.net/figure/Computational-model-of-a-neuron-Source-Leite-2018_fig1_357074876
- 0010 - https://de.wikipedia.org/wiki/Rekurrentes_neuronales_Netz